




파이썬 기반 웹 AI 모의면접 플랫폼 구축

FastAPI, WebRTC, 생성형 AI를 융합한 차세대 실시간 채용 솔루션 상세 설계

Project Status:	Version: 1.0	
Project Status:	 	
Ready for Development		

비즈니스 병목 해결과 데이터 기반 평가의 실현

Problem (문제점)




채용 병목 (Hiring Bottleneck)

시간/장소 제약 및 면접관의
주관적 편향 발생.

비용 과다 (High Cost)

수천 명의 지원자 검증에 소요되는
막대한 운영 비용.

Solution (솔루션)



Generative AI & Vision

단순 키워드 매칭을 넘어선
심층 역량 평가.

Objective Analysis

비언어적 태도(표정, 톤)와
언어적 내용(논리력) 동시 분석.

Goal (목표)

1.5s

End-to-End Latency

자연스러운 대화 흐름 보장.

Capacity

Kubernetes 기반 대규모
동시 접속 처리.


심층 인터뷰를 위한 핵심 사용자 경험 설계

01. 면접 시뮬레이션 엔진

**적응형 꼬리 질문
(Adaptive Questioning)**
LangChain 메모리 활용, 답변
내용 분석 후 구체적 후속 질문 생성
(예: MSA → 트랜잭션 관리).

실시간 개입 (Interruption)
VAD 기술 적용, 주제 이탈 시
AI의 정중한 개입.

02. 기술 역량 평가 도구



Live Coding IDE
샌드박스 환경 내 코드 실행,
시간 복잡도 및 스타일 분석.

System Design Whiteboard
GPT-4V 활용, 아키텍처 다이어그램
시각적 인식 및 타당성 평가.


03. 결과 리포팅



STAR 기법 분석
Situation, Task, Action,
Result 구조 기반 답변 분석.

합격 예측 스코어링
데이터 기반 합격/불합격
예측 점수 산출.


이벤트 기반 마이크로서비스 아키텍처



고성능 처리를 위한 전략적 기술 스택 선정

Backend Framework	FastAPI VS Django	비동기 I/O (Async I/O) 지원으로 WebRTC 시그널링 및 다중 AI API 호출 최적화. Pydantic을 이용한 강력한 데이터 검증.
Real-time Communication	Server-Side Processing (SFU) VS P2P	오디오(STT)와 비디오(Vision AI) 스트림을 서버에서 분기(Forking)하여 실시간 중앙 분석 수행 필수.
Task Queue	Celery + Redis	리포트 생성 및 영상 인코딩 등 무거운 연산 비동기 처리. LLM 단기 메모리(Context) 관리.



1.5초 이내 초저지연 파이프라인 엔지니어링



Optimization Techniques


- 1. Streaming API: 오디오 청크(Chunk) 단위 전송.
- 2. Parallel Processing: STT 변환과 감정 분석(Vision) 병렬 실행.
- 3. Optimized VAD: 발화 종료 감지 알고리즘 고도화.

지능형 대화 엔진: RAG 및 페르소나 전략




멀티모달 감정 및 비언어 분석


Vision AI (DeepFace)



- 7가지 감정 확률 분포 (행복, 불안, 공포 등)
- 프레임 단위(1~2 FPS) 분석
- 타임라인 감정 그래프 매핑



Audio Prosody (음성 운율 분석)



- Pitch (높낮이), Jitter (떨림), Speed (속도)
- 자신감 및 긴장도 정량화

스트리밍 최적화 음성 처리 기술

STT Selection: Deepgram Nova-2

Deepgram Nova-2

- 스트리밍 최적화
- Latency < 300ms
- Interim Results (중간 발화) 지원

VS

Whisper

- 배치 처리 중심
- 지연 발생 가능성


실어시간 없음 가능

실어 시간 A에
내부서 풍형한 가능

TTS & Affective Computing


Engine: Hume AI / ElevenLabs

- 상황에 따른 감정적 어조 생성 (격려, 압박 등)
- WebSocket 기반 끊김 없는 양방향 오디오 스트림



데이터 무결성을 위한 스키마 및 API 설계

Entity Relationship Diagram (ERD)



Core API Interface Contract

```
// Evaluation JSON Schema
{
  "technical_accuracy": "integer (1-5)",
  "rubric_match": "boolean",
  "key_observations": ["string"],
  "session_token": "wss_token_xyz"
}
```

명확한 JSON Schema 정의로 데이터 추적성 확보

품질 보증 및 공정성 평가 루브릭

Evaluation Rubric (평가 루브릭)

Criteria (항목)	1 Point (미흡)	3 Points (보통)	5 Points (탁월)
개념 이해도	오개념 존재	정의 가능, 사례 부족	Trade-off 및 심층 원리 설명
문제 해결력	실마리 못 찾음	힌트 후 해결	최적해 도출 및 대안 비교

Performance Metrics (성능 지표)

- STT WER (단어 오류율) < 10%
- Emotion Accuracy > 80%
- Bias Check: 성별/인종/억양 편향성 검증 데이터셋 테스트

7주 완성 프로젝트 실행 로드맵




보안 및 엔터프라이즈급 확장성



Security & Compliance

- Data Encryption: TLS 1.3 (전송), AES-256 (저장)
- Regulation: GDPR/CCPA 준수 (데이터 영구 삭제 권리)
- Biometric Protection: 영상/음성 데이터 암호화 처리



Scalability (확장성)

- Auto-scaling: Kubernetes HPA (Horizontal Pod Autoscaler)
- Traffic Handling: 트래픽 급증 대응 자동 스케일링
- Stateless Architecture: 수평적 확장 용이성 확보

결론 및 향후 발전 방향

Project Value Proposition



Robustness:
FastAPI + WebRTC
기반의 견고한 엔지니어링



Intelligence:
LangChain + RAG
기반 맥락 인식 대화



Fairness:
객관적 데이터 기반의
공정성 확보

Future Roadmap

- Multi-turn Enhancement: 장시간 대화 문맥 유지 강화
- Custom Fine-tuning: 기업별 인재상 맞춤형 LLM 모델 도입

프로젝트 산출물 체크리스트

Planning & Architecture

- ☐ 프로젝트 헌장 (Project Charter)
- ☐ 요구사항 정의서 (SRS) v1.0
- ☐ 시스템 아키텍처 설계서 (SAD)

Development & Design

- ☐ API 명세서 (Swagger/OpenAPI)
- ☐ 데이터베이스 ERD
- ☐ UI/UX 와이어프레임

Quality & Operation

- ☐ AI 모델 검증 보고서 (Model Card)
- ☐ 테스트 계획서 및 결과서
- ☐ 사용자/관리자 매뉴얼